

PROBLEMATIQUE - Quels troubles expliquent le mieux la prevalence de la depression ?

Meilleur modele

RandomForest

selection selon RMSE test

RMSE (test)

0.235

plus bas = meilleur

R2 (test)

0.934


qualite explicative

Plus forte correlation


Bipolarite

avec depression: r=0.19


1) Matrice de correlations




2) Comparaison des modeles



3) Validation du meilleur modele



4) Variables les plus explicatives



Methodologie

- 1) Preparation des donnees: selection des prevalences par trouble et par annee.
- 2) Modeles compares: Regression lineaire, Ridge, RandomForest.
- 3) Strategie de validation: Split temporel: entraînement ≤ 2013 , test > 2013 .
- 4) Environnement technique: pandas, numpy, matplotlib, scikit-learn.

Interpretation, limites et perspectives

Resultat principal: Le modele RandomForest obtient la meilleure performance (RMSE=0.235). Le facteur le plus associe a la depression est Bipolarite avec une correlation de $r=0.19$.
Limites de l'analyse: Les modeles decrivent des associations statistiques mais ne prouvent pas la causalite. L'absence de variables socio-economiques et sanitaires limite l'explication contextuelle.
Pistes d'amelioration: Integrer des variables externes (PIB, acces aux soins), tester des modeles de boosting et comparer les performances par zone geographique.